

① как выведет бинарный линейный классификатор?

$$a(x) = \begin{cases} 1, & \text{если } f(x) > 0 \\ -1, & \text{если } f(x) \leq 0 \end{cases}$$

где $f(x) = w_0 + w_1 x_1 + \dots + w_n x_n = w_0 + \langle w, x \rangle$,

где w_i - веса признаков x_i , $i = \overline{1, n}$
 w_0 - порог

② Что такое отступ? Какие выборы можно сделать из знака отступа?

Отступом алгоритма $a(x) = \text{sign } f(x)$ на объекте x_i наз-ся $M_i = y_i f(x_i)$
(y_i - класс, к которому относится x_i)

$M_i \leq 0 \Rightarrow y_i \neq a(x_i)$ - алгоритм допустил ошибку

$M_i > 0 \Rightarrow y_i = a(x_i)$ - классифицирован верно

③ Считают, что один из признаков x равен 1 и порог не задан, а задан как скалярное произв.


④ $\tilde{Q}(w) = \sum_{i=1}^l L(M_i(w)) \rightarrow \min_w$

Ф-ция эмпирического риска

Ф-ция потерь

⑧ $L(M; (w))$ - функция потерь - заменим
 индикатор $I(M; (x) < 0)$ - более удобные
 для дифференцирования или для применения
 каких-либо других методов оптимизации,
 не имеющих градиента. Функция потерь
 в (1) равна 1, после этого её
 замкнуто (за исключением квадратичной
 функции потерь)

⑨




$$L(M) = \max\{0, 1 - M\}$$

⑨ Регуляризаторы - ограничение значений
 весов модели.


l_1 - регуляризаторы

$$\begin{cases} \bar{Q} = \sum_{i=1}^l L(M_i) \rightarrow \min \\ \sum_{k=1}^m |w_k| \leq \tau \end{cases}$$



ℓ_2 -регуляризатор

$$\left\{ \begin{array}{l} \bar{a} = \sum_{i=1}^m L(M_i) \rightarrow \min \\ \sum_{k=1}^m w_k^2 \leq \tau \end{array} \right.$$



⑩ Если неограничивать степень полинома, веса должны быть достаточно большими; но тогда модель очень неустойчива, т.е. есть резкий перебор, т.е. модель может быть очень переобучена. \Rightarrow Надо штрафовать модель за какие-то веса, например, оптимизировав ф-л добавив сумму модулей весов или квадратов, т.е. применить регуляризацию ℓ_1 или ℓ_2 , то степень полинома не будет очень большой и не будет переобучения.

Введение регуляризатора повышает устойчивость решения w . В случаях, когда минимум эмпирического риска достигается на мин-ве векторов w , регуляризатор выбирает из них вектор с мин. нормой. Тем самым повышается устойчивость алгоритма, уменьшается его обобщающая способность.


3.2 Пусть $w \in \mathbb{R}^2$ имеет нормальное распределение, все его компоненты независ. и имеют равные дисперсии σ^2 .

$$\ln p(w, \sigma^2) = \ln \left(\frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left(-\frac{\|w\|^2}{2\sigma^2} \right) \right) = -\frac{1}{2\sigma^2} \|w\|^2 + \text{const}(w)$$

вероятностный смысл параметра регуляризации. Он обратно пропорционален дисперсии вектора параметров $\tau = 1/\sigma^2$. Увеличив параметр τ , уменьшаем дисперсию параметров, следовательно, затрещаем который w_i принимать слишком большие значения.

3.3 $X = \mathbb{R}^n$, $Y = \{-1, +1\}$

(*) $a(x) = \text{sign} \left(\sum_{j=1}^n w_j x_j - w_0 \right) = \text{sign}(\langle w, x \rangle - w_0)$



Требуем: ~~макс~~
раздел-ам н-ть
максим. далеко
отстоять от ближайших
к ней (...) объектов
обоих классов.

Если выборка линейно неразделима,
будем допускать ошибки.

$\xi_i \geq 0$ - ошибки на x_i , $i = 1, \dots, \ell$.

Введем штраф за суммарную ошибку

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell \\ \xi_i \geq 0, \quad i = 1, \dots, \ell \end{cases}$$

↑
условная задача оптимизации.

$M_i(w, w_0) = y_i (\langle w, x_i \rangle - w_0)$ - отступ

объекта x_i от границы классов

Алгоритм (*) дает ошибку на
объекте $x_i \Leftrightarrow$ когда $M_i \leq 0$.

Если $M_i \in (-1, +1)$, то $x_i \in$ разд-л. полосе

Если $M_i > 1$, то x_i классифицируется неправильно
и как-то не какой-то расст-мер от порога

Из усл. задачи оптимизации \Rightarrow

$$\xi_i \geq 0$$

$$\xi_i \geq 1 - M_i$$

$$\sum_i \xi_i \rightarrow \min$$

Т.е. $\xi_i = (1 - M_i)_+$

Безусл. задача оптимизации

$$Q(w, w_0) = \sum_{i=1}^L (1 - M_i(w, w_0))_+ + \frac{1}{2c} \|w\|^2 \rightarrow \min$$